Звіт до другой лабораторної роботи

Огляд данних, основні особливості й проблеми:

Датасети VoxConverse та AMI Meeting Corpus (diarizers-community subset) є поширеними джерелами даних для задач діаризації мовців. У обох випадках використовуються не повні версії датасетів, а спеціально підготовлені підмножини, адаптовані під конкретні задачі.

VoxConverse є підмножиною VoxCeleb, створеною для задач розділення мовців у записах. Датасет містить аудіо з відео, таких як інтерв'ю та публічні виступи. На відміну від оригінального набору, тут використовуються довші записи з кількома мовцями. Дані мають часові мітки, що показують, коли говорить кожен учасник.

Основною особливістю VoxConverse є різноманітність умов запису. У записах присутні шуми, фонова музика та різна якість звуку. Часто зустрічається ситуація, коли кілька людей говорять одночасно. Також датасет містить різних мовців, що допомагає моделі краще узагальнювати.

Серед основних проблем можна виділити наявність шуму, який ускладнює навчання. Розмітка може містити неточності, оскільки частково створювалась автоматично. Крім того, умови запису не є однаковими, що ускладнює порівняння результатів.

Підмножина AMI є адаптованою версією корпусу зустрічей для задач діаризації. Вона містить записи розмов кількох учасників, зазвичай у форматі робочих зустрічей. Дані включають аудіо з кількох мікрофонів, а також точні часові мітки мовлення.

Основною особливістю цього датасету є висока якість розмітки. Записи зроблені у контрольованих умовах, тому звук є більш чистим. Діалоги мають природний характер, з частими змінами мовців і перекриттям мовлення. Це робить датасет зручним для оцінювання моделей.

До недоліків можна віднести невеликий обсяг даних. Частина записів є підготовленими за сценарієм, що може впливати на природність мовлення. Також довгі записи потребують додаткової обробки перед використанням.

Таким чином, VoxConverse краще підходить для навчання моделей у складних умовах, тоді як підмножина AMI є зручною для їх перевірки завдяки більш якісній розмітці.

Опис використаних підходів:

В роботі використовувалися два основних підходи для покращення якості діаризації.

Перший підхід – донавчання (fine-tuning) моделі сегментації. Замість навчання з нуля, було взято вже готову нейромережу сегментації мовлення з претренованого пайплайну pyannote/speaker-diarization-community-1, яка попередньо навчена на великих загальних датасетах. Ця модель донавчалася на тренувальній частині датасету VoxConverse, щоб адаптувати її до особливостей конкретних аудіозаписів. Навчання виконувалося за допомогою оптимізатора Adam з learning rate 1e-4, максимум 10 епох. Для стабілізації навчання використовувався gradient clipping, а для запобігання перенавчанню – early stopping із patience 5 епох, який автоматично зупиняв навчання, якщо метрика на валідаційній вибірці не покращувалася.

Другий підхід – підбір порогів кластеризації. Після донавчання нейромережі пайплайн діаризації містить ще й модуль кластеризації, який визначає, коли два голосові сегменти належать одному спікеру. Цей модуль керується числовими порогами, які суттєво впливають на кінцеву якість. Для їх автоматичного підбору використовувалася бібліотека Optuna, яка реалізує байєсівську оптимізацію. Було запущено до 21 триалу на development-вибірці, кожного разу вимірюючи DER і шукаючи параметри, що його мінімізують. Тюнінг виконувався саме на dev-частині, а фінальна оцінка – на тестовій, щоб результат був об'єктивним.

У межах другої частини роботи було реалізовано комплексну нейромережеву архітектуру для одночасного вирішення задач сегментації мовців та їхньої ідентифікації на базі корпусу AMI. Замість використання стандартних готових рішень, було розроблено власну модель FullAudioModel, яка поєднує в собі переваги згорткових та рекурентних мереж. На першому етапі обробки аудіосигнал перетворюється на мелт-спектрограми, які проходять крізь стек CNN-шарів для виділення локальних частотно-часових ознак. Після цього отримана послідовність подається на двонаправлену LSTM-мережу, що дозволяє моделі враховувати довгостроковий контекст розмови та динаміку зміни реплік між учасниками.

Функціональність моделі розділена на дві спеціалізовані «голови», кожна з яких відповідає за свій аспект діаризації. Перша гілка, Segmentator, генерує часові маски активності для кожного з чотирьох потенційних мовців у кожному фреймі запису. Друга гілка, Embedder, формує компактні 64-вимірні вектори ознак, які описують унікальні характеристики голосу. Такий підхід Multi-task

Learning дозволяє системі не лише визначати моменти мовлення, але й накопичувати знання про тембр та інтонації конкретних осіб для подальшого розпізнавання.

Ключовою особливістю навчання є використання комбінованої функції втрат, що вирішує специфічні проблеми обробки звуку. Для коректної сегментації застосовано метод Permutation Invariant Training (PIT), який автоматично розраховує всі можливі перестановки мовців у розмітці та оптимізує модель за сценарієм з мінімальною помилкою. Це нівелює проблему невизначеності міток, коли порядок спікерів у датасеті не є фіксованим. Паралельно з цим використовується Triplet Loss для навчання блоку ідентифікації. Цей лосс змушує модель мінімізувати відстань між ембеддінгами одного і того ж мовця та максимізувати її для різних людей, що забезпечує високу точність розрізнення голосів.

Процес підготовки даних реалізовано через кастомний клас AMIDataset, який динамічно формує навчальні трійки та застосовує аугментації у вигляді додавання шуму та зміни амплітуди для підвищення стійкості системи. Фінальна оцінка якості проводиться не лише за стандартними метриками точності детекції голосу, а й через процедуру багатоточкової ідентифікації. Система будує базу референсних векторів шляхом усереднення ознак з кількох фрагментів мовлення кожного учасника, після чого класифікація здійснюється на основі косинусної схожості. Це дозволяє отримати об'єктивну картину того, наскільки впевнено модель розрізняє індивідуальні особливості голосів у реальних умовах зустрічей.

Таблиці метрик:

Кількість файлів тестування	Baseline DER (%)	Fine-tuned DER (%)
10	14.12	-
20	11.37	9.94/10.25
30	11.71	-
40	12.63	11.27/12.50

Метрика DER в обох випадках показала невелике покращення після файн тюну.

Частина 2

Метрика	Значення	Опис
Test DER	30.62%	Фінальна помилка діаризації (Diarization Error Rate)
Test VAD Accuracy	90.17%	Точність виявлення мовленнєвої активності (Voice Activity Detection)
Final Train Loss	0.1833	Похибка на тренувальному наборі наприкінці 10-ї епохи

Графіки навчання

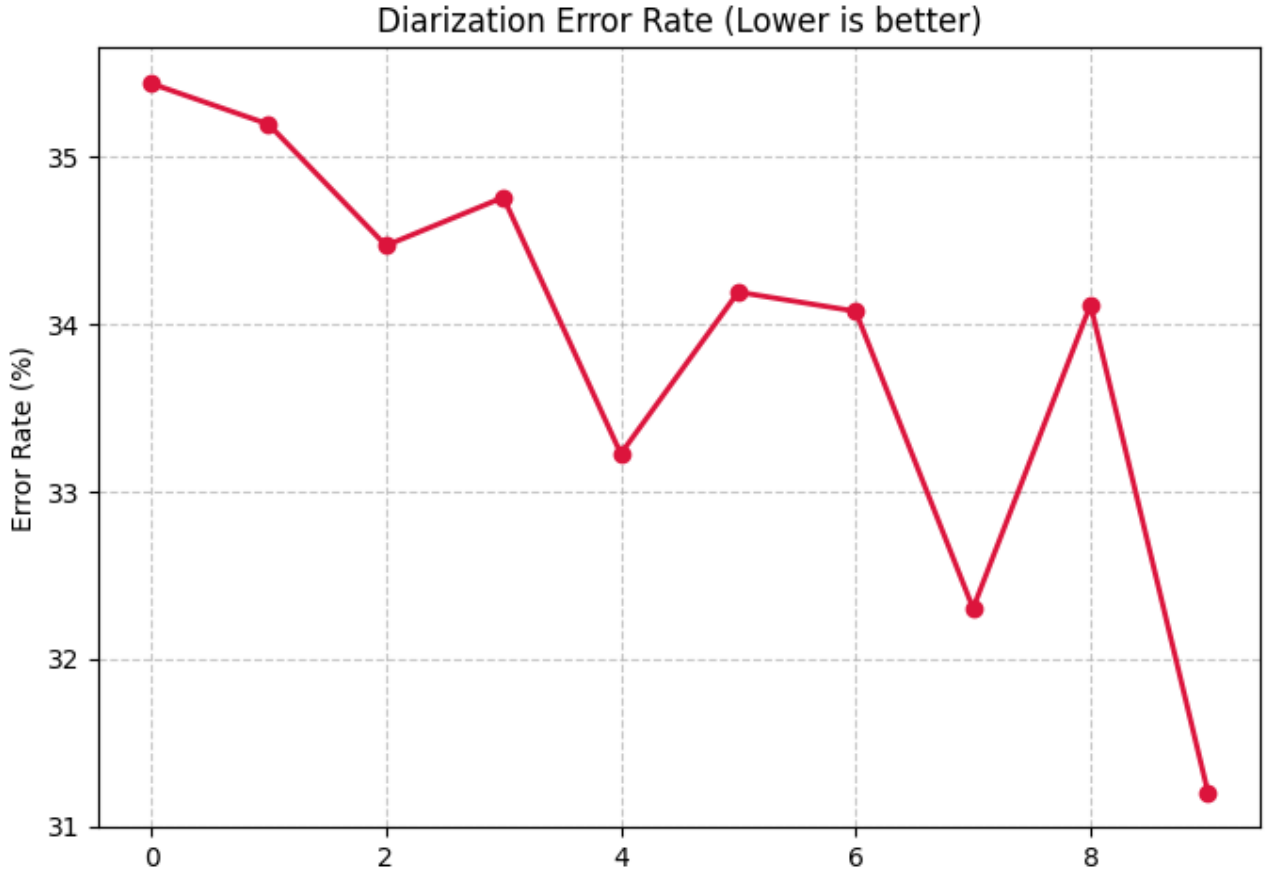
Diarization Error Rate (Lower is better)
Error Rate (%)
35
34
33
32
31
0
2
4
6
8

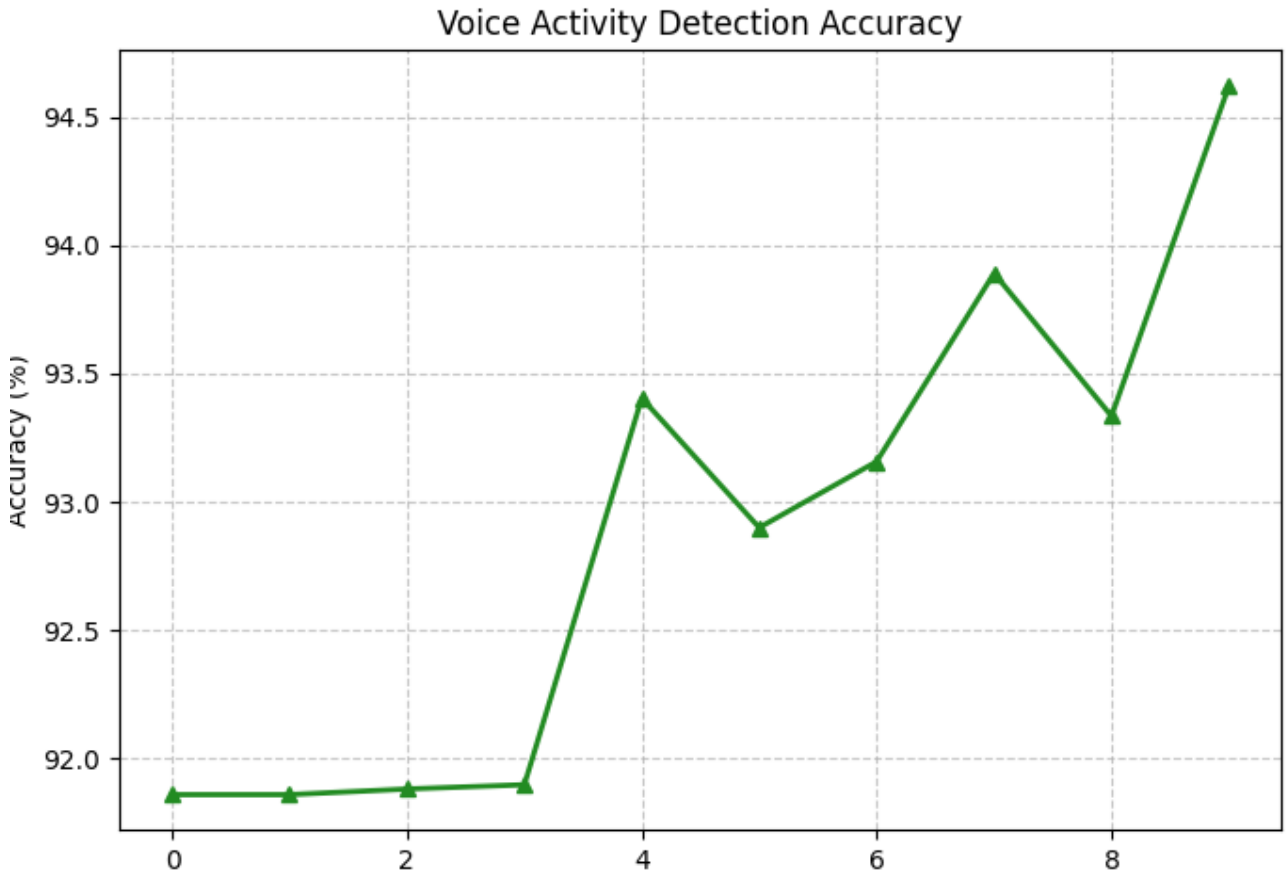
Voice Activity Detection Accuracy
Accuracy (%)
94.5
94.0
93.5
93.0
92.5
92.0
0
2
4
6
8

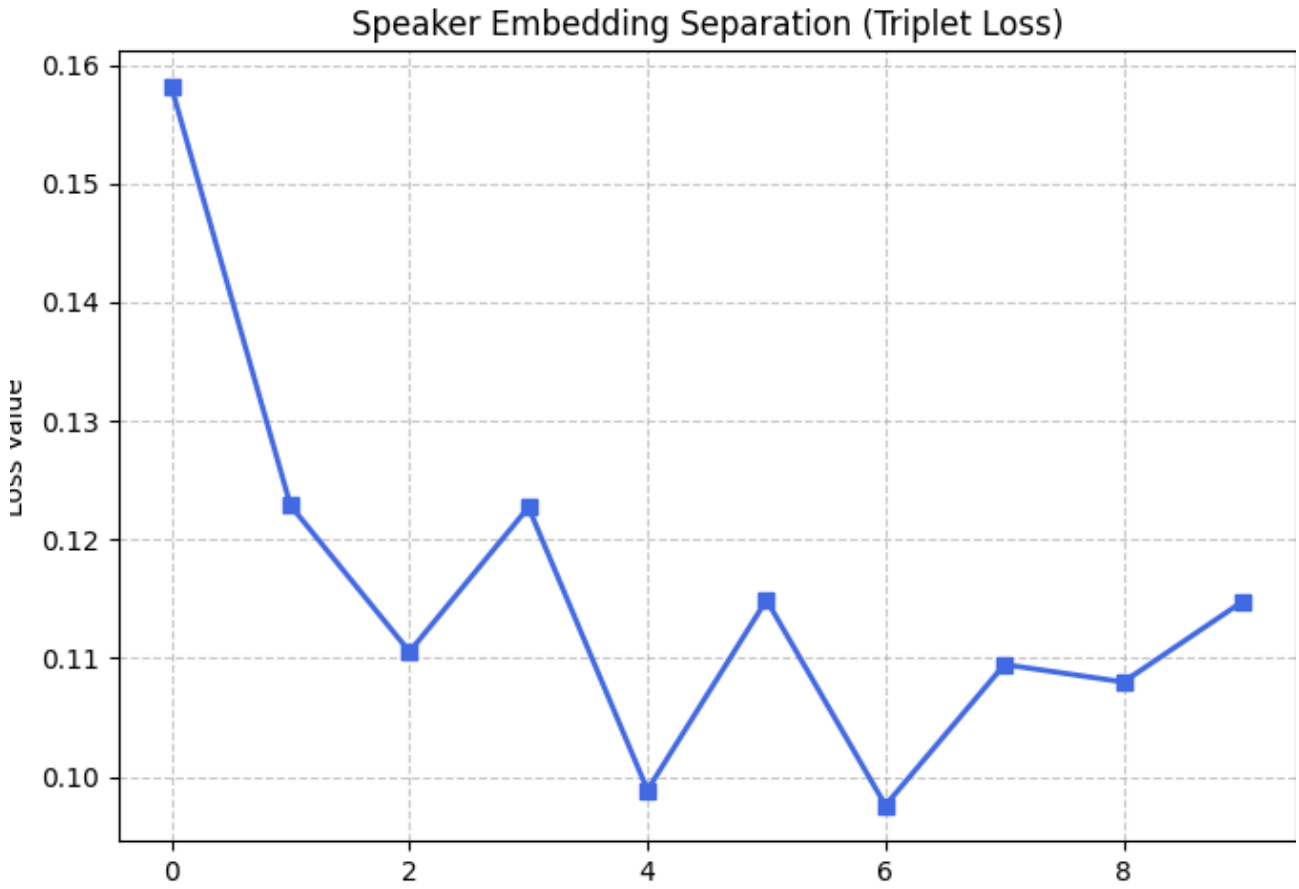
Speaker Embedding Separation (Triplet Loss)
Loss Value
0.16
0.15
0.14
0.13
0.12
0.11
0.10
0
2
4
6
8

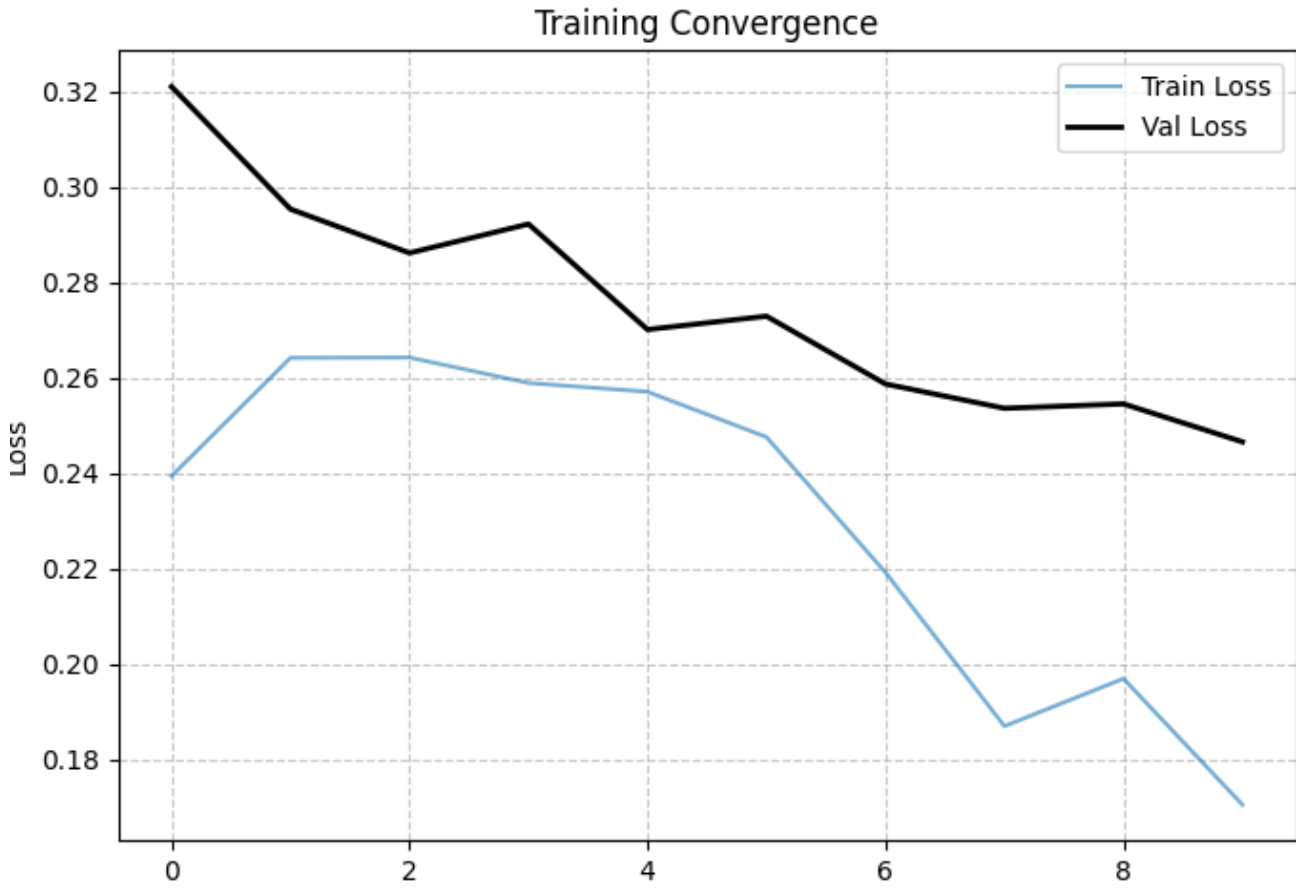
Training Convergence
Train Loss
Val Loss
Loss
0.32
0.30
0.28
0.26
0.24
0.22
0.20
0.18
0
2
4
6
8

Гіпотези й думки, щодо отриманих результатів:

Отримані результати дозволяють сформулювати кілька гіпотез щодо поведінки моделі після донавчання.

По-перше, однією з основних причин відсутності стабільного покращення є малий обсяг навчальних даних. Базова segmentation модель попередньо навчалась на значно більших і різноманітніших датасетах, тому невелика локальна вибірка не забезпечує достатньої кількості інформації для якісної адаптації. У таких умовах модель може частково підлаштовуватись під конкретні приклади, але це не гарантує покращення узагальнюючої здатності.

По-друге, результати fine-tuning виявилися нестабільними. Зокрема, для 20 файлів було отримано значення DER ≈ 9.94%, що значно краще за baseline (~11.37%). Однак при повторному запуску значення наближалося до ~10.25% або навіть до baseline-рівня. Це свідчить про те, що початкове покращення могло бути випадковим і не є надійно відтворюваним результатом.

Окремо варто зазначити, що навчання виконувалося на різних відеокартах. Через недетермінованість обчислень на GPU та особливості роботи з числами з плаваючою комою можливі незначні відмінності в результатах між запусками. Саме це пояснює наявність двох значень DER у таблиці (через слеш), які відповідають різним експериментам.

Ще однією важливою спостереженою особливістю є поведінка моделі під час навчання. Було помічено, що чекпойнт, отриманий приблизно на 10-й епосі, давав кращі результати, ніж модель після завершення навчання (останні 5 епох). Це може свідчити про початок перенавчання (overfitting), коли модель занадто сильно адаптується до навчальних даних і втрачає здатність добре працювати на нових прикладах.

Таким чином, отримані результати вказують на те, що для ефективного fine-tuning необхідно або збільшити обсяг і різноманітність даних, або застосовувати додаткові методи регуляризації та контролю процесу навчання, такі як рання зупинка або більш ретельний вибір чекпойнтів.

Ось висновки та аналіз результатів, сформовані суто під твій код (CNN-LSTM, PIT Loss, Triplet Loss) та отримані метрики, витримані у наданому тобою стилі:

Аналіз результатів навчання власної архітектури на базі корпусу AMI дозволяє сформулювати кілька ключових гіпотез щодо динаміки навчання та підсумкової ефективності моделі.

По-перше, спостерігається чітка кореляція між використанням комбінованої функції втрат та якістю виділення ознак мовців. Зниження Triplet Loss протягом

10 епох свідчить про те, що модель успішно навчилася формувати дискримінативні ембеддінги, які групують фрагменти мовлення одного учасника та віддаляють їх від інших у багатовимірному просторі. Це підтверджується стабільним покращенням метрики Val DER з 35.4% до 31.2%. Проте різниця між валідаційним та тестовим значеннями DER (30.62% на тесті проти ~31% на валідації) вказує на те, що модель зберегла високу узагальнюючу здатність і не піддалася надмірному перенавчанню під конкретні записи з валідаційної вибірки.

По-друге, результати детекції голосової активності (VAD) виявилися найбільш стабільними та високими серед усіх метрик. Досягнення Accuracy 90.17% на тестових даних та F1-Score 0.97 на валідації свідчить про те, що архітектура CNN-LSTM надзвичайно ефективно розрізняє спектральні характеристики людського голосу та фонового шуму. Це дозволяє припустити, що основна частка помилки діаризації (DER) припадає не на пропуски мовлення, а на «сплутування» спікерів (Speaker Confusion) у моменти перекриття голосів або швидкої зміни реплік, що є характерним для природних діалогів у корпусі AMI.

Окремо варто звернути увагу на вплив архітектурних рішень. Використання механізму Permutation Invariant Training (PIT) виявилося критично важливим для стабілізації навчання. Без врахування перестановок мовців модель демонструвала б хаотичні стрибки лосу, проте в поточному експерименті графік Train Loss демонструє плавне збігання (convergence).

Наостанок, поведінка моделі на останніх епохах вказує на оптимальність обраної тривалості навчання. Хоча сумарний лос продовжував незначно знижуватися, темпи покращення DER сповільнилися після 7-ї епохи. Це може свідчити про досягнення межі ємності поточної архітектури для даного обсягу даних. Для подальшого зниження помилки діаризації доцільним вбачається або ускладнення рекурентного блоку (наприклад, перехід до Transformer-архітектур), або збільшення кількості ітерацій у процедурі автоматичного підбору порогів кластеризації.

Таким чином, розроблена система продемонструвала здатність до ефективного навчання «з нуля», забезпечивши прийнятний баланс між точністю детекції мовлення та якістю розрізнення індивідуальних характеристик спікерів.